Revisión de la entrega del 30/10

Qué está bien, qué se corrigió, qué falta y qué tienen que hacer ustedes antes de clase

PAREJA

Ana Sofía Arango Yanza · Juan José Arias Chacua

CÓMO SE REVISÓ

Contra el enunciado del profe (PDF del proyecto y de las exposiciones), con dos revisiones independientes: Claude Code y un segundo agente revisor de solo lectura

FECHA Y VERSIÓN

29/10/2026 · v1

1 Semáforo frente al punto de control

El caso base, el GQM y la spec están bien. Lo que todavía no existe es la **línea base medida**, y eso solo lo pueden hacer ustedes.

Lo que pide el enunciado	Estado	Qué falta	Quién
Caso base ≥ 10 casos con material difícil	Cumple	Comprobado: 24 tareas (11 S · 11 M · 2 L), 10 difíciles, 17 ítems de Jira, 39 pruebas visibles y 71 ocultas	—
Caso **congelado** antes del agente	No	No hay commit `congelado v1` . El HTML v1 lo daba por hecho	Pareja
Especificación v1 (8 campos)	Corregida	La versión md y la del HTML no coincidían; ya se unificaron. Falta **fijar la herramienta y el modelo**	Pareja
GQM	Corregido (v2)	M3 normalizada, M5 y M6 bien definidas	—
Línea base medida (≥ 10, condiciones)	No hay datos	Medir las 10 tareas con grabación, hoja de sesiones y hoja de medición	Pareja
3 casos para otra pareja	Pendiente	Dependen del tema de la otra pareja. Proponer al profe el formato (ficha + pruebas)	Pareja

2 Qué se corrigió hoy

Problema encontrado	Corrección	Archivo
El sorteo no estratificaba. Con cualquier semilla, la línea base quedaba con 7 S, 2 M y 1 L, y el agente con 4 S, 7 M y 1 L: la línea base salía más fácil.	Cupos fijos por tamaño (línea base 5 S · 4 M · 1 L; agente 5 S · 6 M · 1 L), difíciles repartidas alternando y **orden de tareas sorteado**. Probado con 300 semillas.	`main` : `sorteo.py` (commit 85089e4)
`python -m pytest` sin ruta corría también las 71 pruebas **ocultas**: el dato se podía contaminar.	Por defecto ahora solo corre `tests/visibles` ; las ocultas se corren a propósito.	`main` : `pyproject.toml`
A la hoja de medición le faltaban M2, M4 (minutos), M6 (pronóstico y ayuda percibida), las condiciones de cada sesión y el codewalk por pregunta. Las hojas Excel estaban en azul.	**Bitácora v2** con la paleta Macarons y 6 hojas: Instrucciones, Sesiones, Medición (con fórmulas), Codewalk, Bitácora y Resumen. Listas desplegables para Decisión y Marcas.	`05 - Ciclos y bitacora/Versiones anteriores/v2/29102026_01_Bitacora_v2.xlsx`
La spec del md no coincidía con la del HTML: entradas que no existen (DoD, glosario), "pruebas propuestas" contra "no tocar pruebas", y no excluía las ocultas.	Spec v1 unificada, que es la que se presenta.	`04 - …/29102026_01_Spec_Copiloto_v1.md`
M3 no estaba normalizada (t23 tiene 2 ocultas), el codewalk era ambiguo (¿con o sin código?) y M6 no estaba definida para la línea base.	GQM v2.	`03 - Linea base/Versiones anteriores/v2/29102026_01_GQM_v2.md`
Hipótesis apoyadas en preprints y en un blog (METR, Anthropic). Shihab y Welter citados solo por arXiv; Welter tiene otro título en ASE.	Fuentes v2: **20 artículos revisados por pares**, con DOI verificado en Crossref y OpenAlex, y la literatura gris aparte.	`01 - Exposicion/Fuentes/29102026_01_Fuentes_v2.md`

Problema encontrado	Corrección	Archivo
No estaba claro cómo presentar resultados con n ≈ 10.	Guía de medición y presentación: mediana y rango, A12, sin p-valores, amenazas a la validez.	`01 - …/29102026_02_Como_Medir_y_Presentar_v2.md`
La línea base había que pasarla a mano al PDF.	Un script calcula el resumen desde los datos crudos y llena §5 del punto de control (con sus condiciones) y genera el PDF.	`07 - Analisis/Scripts/resumen_medicion.py`
Documento del punto de control con estados falsos ("Listo / 26/10") y citas débiles.	**Punto de control v2**.	`09 - …/29102026_02_Punto_Control_v2.pdf`

3 Lo que tienen que hacer ustedes, en orden

LO MÁS IMPORTANTE

Sin la línea base medida, el punto de control no cumple. Si no alcanzan las 10 tareas antes de clase, lleven el **n real** con la marca `[N]` y díganselo al profe tal cual. Nunca se completa de memoria.

1. **Decidir dos tareas dudosas (5 min).** En el backlog, Juan José aparece como autor del PR de **t08** (cameia-web#64), pero t08 no está marcada como "ya la hizo". Y **t14** sale de perfil#88, donde Ana Sofía figura como coautora. Si alguno ya implementó esas reglas, se agregan a `AUTOR` en `sorteo.py` *antes* de sortear.

2. **Hacer el sorteo y guardarlo.** `git pull` en `main` y luego `python sorteo.py <semilla> > registro/sorteo_<semilla>.txt`. Anoten la semilla en la hoja Sesiones y en un acta en `09 - Control de entrega/Actas pareja/`.

3. **Congelar el caso.** Un commit `congelado v1` (mejor con el tag `git tag congelado-v1`) y la fecha en el CHANGELOG. Desde ahí no se tocan ni las tareas ni las pruebas.

4. **Fijar la herramienta y el modelo del agente** en la spec v1 (Claude Code, Copilot o Cursor, con la versión exacta). Si es Claude, se declara como limitación.

5. **Medir la línea base** en el orden que imprimió el sorteo, grabando la pantalla y llenando la bitácora v2 *al terminar cada tarea*. Calculen unas 6–8 h en total, porque cada tarea suma unos 15 min de pronóstico, ocultas, codewalk y hoja. Partanlo en dos sesiones.

6. **Generar el documento:** `python "07 - Analisis/Scripts/resumen_medicion.py" "05 - Ciclos y bitacora/Versiones anteriores/v2/29102026_01_Bitacora_v2.xlsx" --html "09 - Control de entrega/Versiones anteriores/v2/29102026_02_Punto_Control_v2.html"`. Eso llena §5 y regenera el PDF.

7. **Recálculo independiente:** la persona que no corrió el script calcula a mano una mediana y lo anota en la hoja Sesiones. La cifra lleva `[R]`.

8. **Completar la declaración de uso de IA** (§10 del punto de control): qué revisaron ustedes y qué fuentes leyeron. Abran al menos el resumen de las 4 que sostienen las hipótesis y pásenlas a `[V]` con su página.

9. **Revisar la privacidad:** el backlog de origen, que es público en GitHub, tiene nombres de compañeros de CAMEIA (autores de los PR). Decidan si los dejan, con el permiso del equipo, o si los cambian por iniciales.

10. **En clase:** mostrar el repo, el PDF v2 y la bitácora; hacer las 3 preguntas de §8; recibir los 3 casos y guardar la respuesta del profe por escrito.

4 Lo que el profe puede preguntar, y cómo responder

Posible crítica	Respuesta preparada
"El caso es sintético, no es su trabajo real."	Cada tarea es una regla real de un PR fusionado de CAMEIA, y está trazada en el backlog de origen. Se aisló para que el cronómetro mida la práctica y no montar Docker. Es una limitación declarada: no medimos el costo de integración.
"Lo diseñaron con IA: es el caso que su agente resuelve bien."	Lo declaramos como amenaza. Por eso el caso se congela antes de usar el agente, las pruebas ocultas no las ve nadie, y recibimos 3 casos de otra pareja.
"El esfuerzo siempre favorece al agente: 2 personas contra 1."	Sí. Por eso M1 y M2 se reportan juntas y nunca solo M2, como en Arisholm 2007.
"Con 10 tareas no pueden concluir nada."	Correcto: reportamos mediana, rango y A12 de forma descriptiva, sin causalidad (Kitchenham 2017). Un resultado negativo bien medido también vale.
"El aprendizaje entre semanas sesga la comparación."	El orden se sortea dentro de cada etapa y lo declaramos. No se puede contrabalancear del todo, porque la línea base debía ir antes del 30/10 por enunciado.
"¿Por qué el compañero entiende menos? Si no participó..."	Justamente: M5-compañero mide la **transferencia de conocimiento** que se pierde (Plonka 2015; Welter 2025). Es la pregunta del tema.

5 Cifras para llevar escritas (las dos personas)

CASO BASE

24 · 10

tareas · difíciles (17 ítems de Jira, 5 repos)

PRUEBAS

39 + 71

visibles + ocultas = 110

SORTEO

10 · 12 · 2

línea base · agente · repuesto

Arisholm 2007: la pareja usó **84 % más esfuerzo** y solo mejoró la corrección en el sistema complejo. Welter 2025: con Copilot se acepta con **menos escrutinio**. Shihab 2025: 35 % más rápido, pero **sin entender por qué** funcionaban las sugerencias. Perry 2023: código **menos seguro** y más confianza.